

陈卓玮

✉ johnny.zhuowei.chen@gmail.com 📞 +86 13602337187

教育

广东外语外贸大学 (GDUFS)
软件工程学士学位; 导师: 王连喜
GPA: 3.80/4.00

中国, 广州
2021.09 - 2025.06

加州大学伯克利分校 (UC Berkeley)
课程: NLP, AI 导论, 计算机安全
GPA: 4.00/4.00

美国, 伯克利
2023.08 - 2024.06

相关发表

* 代表同等贡献, † 代表通讯作者。

- Zhuowei Chen**, Qiannan Zhang, Shichao Pei. **Injecting Universal Jailbreak Backdoors to LLMs in Minutes**. *The Thirteenth International Conference on Learning Representations, ICLR 2025*.
- Zhuowei Chen**, Yuben Wu, Xinfeng Liao, Yujia Tian, Lianxi Wang[†]. **An Effective Deployment of Diffusion LM for Data Augmentation in Low-Resource Sentiment Classification**. *The 2024 Conference on Empirical Methods in Natural Language Processing, EMNLP 2024*.
- Lianxi Wang, Yujia Tian*, **Zhuowei Chen***[†]. **Enhancing Hindi Feature Representation Through Fusion of Dual-Script Word Embeddings**. *The Joint Conference on Computational Linguistics, Language Resources and Evaluation, LREC-COLING 2024*.
- Zhuowei Chen**, Yujia Tian, Lianxi Wang[†], Shengyi Jiang. **A Distantly-Supervised Relation Extraction Method Based on Selective Gate and Noise Correction**. *The 22nd China National Conference on Computational Linguistics, CCL 2023*.
- Lianxi Wang, Huayu Huang, **Zhuowei Chen**[†]. A Knowledge-Augmented and Label-Aware Framework for Multi-Label Text Classification. (在审 @ *Journal of Computer Science and Technology*)
- Lianxi Wang, Yujia Tian*, **Zhuowei Chen***, Mutong Li, Nankai Lin[†]. EditMDS: An Iterative Optimization Method for Multi-Document Summarization Based on Edit Operations. (在审)

研究及工作经历

麻省大学 (波士顿)
研究实习生
导师: 裴仕超

美国, 波士顿
2024 年 3 月 - 2024 年 12 月

- JailbreakLLM: 探索对大型语言模型 (LLMs) 的新型后门攻击。(ICLR 2025)
 - 提出了一种无需额外数据集或大量计算开销的方法, 向 LLM 中注入通用后门。
 - 开发了多节点目标估计, 在保持攻击隐匿性同时, 有效削弱并绕过 LLM 的内部安全机制。
 - 进行了全面实验, 验证了高成功率的越狱效果, 强调了开发高级防御策略的紧迫性。

慧科讯业 | 人工智能实验室
NLP 实习生

中国, 深圳
2023 年 12 月 - 2024 年 3 月

- 基于 BERT 的文本分类模型构建, 使用人工标注的社交媒体内容。
- 应用 transformer 模型进行时间序列回归, 以预测到港访客量。

广州多语种智能处理重点实验室
本科生
导师: 王连喜

中国, 广州
2021 年 11 月 - 2024 年 3 月

- 使用扩散语言模型 (Diffusion LM) 进行文本分类的数据增强。(EMNLP 2024)
 - 通过扩散目标对语言模型进行微调以捕获领域知识, 并通过重构标签相关的标记生成样本。
 - 设计了基于注意力的掩码调度机制, 以平衡领域一致性、标签一致性和上下文多样性。
 - 通过分析和可视化研究其工作机制, 实验验证了其在低资源场景中的有效性。

- 通过融合预训练语言模型增强印地语表示能力。(COLING 2024)
 - 提出一种结合天城文和罗马化印地语预训练语言模型的方法，以增强印地语特征表示。
 - 深入比较了不同特征融合技术，包括拼接、求和和交叉注意力。
 - 消融实验和充分的 NLP 实验表明，该方法在增强低资源语言模型方面具有优势。
- 使用噪声学习方法进行远程监督关系抽取。(CCL 2023)
 - 结合选择门机制与噪声校正训练框架，通过三阶段训练框架进行数据选择和噪声标签校正。
 - 实验表明，该方法在性能上达到了 SOTA 水平，为在自然语言处理中应用噪声学习方法提供了新的可能性。
- 结合知识增强和跨度预测的多标签文本分类。
 - 结合跨度预测和基于图神经网络的知识增强模块，以改进多标签文本分类。
 - 进行了可视化和分析以研究其工作机制，强调了整合领域知识对于语言模型的重要性。

项目经历

- BiasLLM：对 LLM 的对抗性知识编辑攻击。
 - 将图神经网络（GNN）与“定位然后编辑”（ROME）技术相结合，对 Llama-2 模型进行攻击，成功揭示了模型中的显著偏差。
- 多模态自然语言处理：使用 CLIP 和理性语言行为理论实现图文交互。
 - 使用 CLIP 模型进行图像和标题的检索，并通过开发理性语言行为推断程序进一步提升检索效果。

语言与技能

- 编程语言: Python, SQL, Java, JS/HTML/CSS, C/C++, Golang
- 语言能力: 英语 (IELTS 7.5)

荣誉

- 中国国家奖学金教育部, 2024
- 综合一等奖学金(Top 4%) 广东外语外贸大学, 2024
- 综合一等奖学金(Top 4%) 广东外语外贸大学, 2023
- 二等奖(Top 5%) 中国计算机设计大赛, 2022
- 三等奖全国大学生数学建模竞赛 (广东省), 2023